



Clase 1 - Semana 1

Ciencia de datos

Universidad de Oriente

Facultad de Ingeniería y Arquitectura

17 de julio del 2026

Introducción a Data Science

Esta es una materia orientada al estudio y aplicación de la ciencia de datos, una disciplina que ha adquirido gran importancia en los últimos años. Sin embargo, antes de profundizar en sus herramientas y métodos, surge una pregunta fundamental: ¿qué es la ciencia de datos?

Aunque el término se utiliza con mucha frecuencia en la actualidad, no siempre resulta sencillo definirlo con precisión. Algunas críticas lo consideran una etiqueta innecesaria, argumentando que toda ciencia trabaja con datos; otras lo ven simplemente como una palabra de moda asociada al ámbito tecnológico y laboral. No obstante, estas opiniones dejan de lado un aspecto esencial: la ciencia de datos representa una combinación de conocimientos y habilidades que hoy son cada vez más necesarias en distintas áreas de la industria, la investigación y la academia.

Introducción a Data Science

La ciencia de datos puede entenderse como una disciplina interdisciplinaria que integra tres grandes componentes. En primer lugar, incorpora elementos de la estadística, necesarios para describir, analizar, modelar e interpretar conjuntos de datos. En segundo lugar, requiere conocimientos de computación, especialmente para almacenar, procesar, visualizar y analizar datos de manera eficiente mediante algoritmos y herramientas tecnológicas. Finalmente, necesita conocimiento del área de aplicación, ya que este permite formular preguntas adecuadas, interpretar correctamente los resultados y tomar decisiones con base en el contexto.

Por tanto, la ciencia de datos no se limita únicamente al uso de programas o lenguajes de programación, ni tampoco se reduce al análisis estadístico. Más bien, consiste en la integración de métodos matemáticos, estadísticos y computacionales con el conocimiento específico de un problema real. Esta combinación permite transformar datos en información útil, generar conocimiento y apoyar la toma de decisiones en diversos campos.

Introducción a Data Science

Con esta idea en mente, es conveniente comprender la ciencia de datos no necesariamente como una nueva área de conocimiento aislada, sino como un conjunto de habilidades que pueden aplicarse dentro de distintos campos de especialización. Su valor principal radica en que permite analizar problemas desde una perspectiva basada en datos, independientemente del área en la que se trabaje.

Por ejemplo, la ciencia de datos puede utilizarse para analizar resultados electorales, predecir comportamientos financieros, optimizar campañas publicitarias en línea, identificar microorganismos en imágenes de microscopio, descubrir nuevos objetos astronómicos o estudiar información proveniente de cualquier otro campo.

Introducción a Data Science




Figure: Diagrama de Venn de la ciencia de datos

Introducción a Data Science

Las tareas de ciencia de datos suelen describirse como un proceso, y esta sección proporciona una visión general de cada paso de dicho proceso. Estas tareas siguen un procedimiento llamado ciclo de la ciencia de datos, el cual incluye la definición del problema, seguida de la recolección, preparación, análisis y presentación de los datos, como se ilustra en la Figura.



Introducción a Data Science

Aunque la recolección y preparación de datos pueden parecer tareas simples en comparación con el trabajo más importante del análisis, en realidad son las etapas que consumen más tiempo y esfuerzo dentro del ciclo de la ciencia de datos. Según una encuesta realizada por Anaconda (2020), los científicos de datos dedican aproximadamente la mitad de todo el proceso a la recolección y limpieza de datos, mientras que el análisis de datos y la comunicación ocupan alrededor de una cuarta parte a un tercio del tiempo cada uno, dependiendo del trabajo.

Introducción a Data Science

Definición del problema

El primer paso consiste en establecer claramente qué se desea resolver o investigar.

- Formular una pregunta o problema específico.
- Definir los objetivos del análisis.
- Delimitar el alcance del proyecto.
- Identificar qué tipo de datos serán necesarios.

Recolección de datos

La recolección de datos es el proceso de obtener información sobre variables de interés. Los datos pueden provenir de encuestas, transacciones, plataformas digitales, entre otras fuentes.

Preparación de datos

Los datos recolectados rara vez están listos para ser analizados. Por eso deben limpiarse y organizarse. Esta etapa incluye:

- Corregir errores.
- Tratar valores faltantes
- Eliminar duplicados.
- Revisar datos inconsistentes.
- Unificar formatos.

Una buena preparación permite obtener resultados más confiables.

Análisis de datos

Una vez preparados, los datos se analizan para descubrir patrones, relaciones o información relevante. Las técnicas más comunes son:

- Cálculo de mínimos y máximos.
- Estadística descriptiva.
- Visualización de datos.
- Análisis de relaciones entre variables.
- Modelos predictivos.
- Aprendizaje automático.

Generalmente se inicia con métodos simples y luego se avanza hacia técnicas más complejas.


Reporte de datos

El reporte consiste en comunicar los resultados del análisis de forma clara y comprensible. Esto puede incluir:

- Tablas
- Gráficos.
- Diagramas.
- Informes.

El objetivo es que los hallazgos puedan ser entendidos por otras personas y utilizados para tomar mejores decisiones.

Introducción a Data Science




Análisis exploratorio de los datos

El análisis exploratorio de datos (EDA) propuesto seguirá estos pasos:

- Se realiza un análisis descriptivo de las variables con el propósito de obtener una idea representativa del conjunto de datos.
- Se ajustan los tipos de variables para garantizar la consistencia en las operaciones posteriores
- Se detectan y tratan los datos faltantes para procesar adecuadamente las variables numéricas. Los datos faltantes corresponden a valores no registrados en algunas observaciones, por lo que es fundamental gestionarlos correctamente para evitar sesgos y problemas en el análisis.
- Se identifican y tratan los valores atípicos con el fin de evitar que distorsionen los análisis estadísticos posteriores.

Análisis exploratorio de los datos

El siguiente gráfico representa esquemáticamente el conjunto de etapas del análisis exploratorio de datos descritas anteriormente.



Análisis exploratorio de los datos

En la fase del análisis descriptivo constituye la base para realizar análisis posteriores más profundos y específicos. La visualización gráfica de datos constituye un pilar fundamental en el proceso de análisis exploratorio. Las representaciones visuales no solo complementan los análisis numéricos, sino que también permiten revelar aspectos importantes de los datos que podrían pasar desapercibidos mediante métodos puramente cuantitativos.

La selección del tipo de visualización más adecuado para cada análisis resulta fundamental, ya que una representación gráfica apropiada facilita la comprensión de los datos y mejora la comunicación de los resultados.

Análisis exploratorio de los datos

Después de la carga inicial, es esencial verificar la correcta codificación del tipo de dato correspondiente a cada variable. Un tipo de dato inadecuado puede comprometer los análisis posteriores o generar resultados erróneos.

Es necesario confirmar que las variables numéricas estén efectivamente almacenadas como números, ya sean enteros o decimales, mientras que las variables cualitativas o categóricas deben codificarse como cadenas de caracteres y contener un conjunto finito y bien definido de categorías.

Esta verificación temprana permite identificar y corregir posibles inconsistencias en la tipología de los datos, como fechas almacenadas como texto o categorías codificadas incorrectamente como valores numéricos.

Análisis exploratorio de los datos

La presencia de datos faltantes, también conocidos como valores perdidos o NaN (Not a Number) en Python, es una situación común en muchos conjuntos de datos y puede representar un desafío importante en el análisis de datos. Estos valores faltantes pueden surgir por diversas razones, como errores durante la transcripción de los datos, problemas en el proceso de recolección o incluso porque ciertos valores no estaban disponibles en el momento de la medición.

Los datos faltantes pueden distorsionar los resultados del análisis, afectar la precisión de los modelos predictivos y alterar las visualizaciones gráficas, lo que puede conducir a interpretaciones incorrectas o engañosas. Por ejemplo, si no se tratan correctamente, los datos faltantes pueden sesgar los resultados de una regresión o disminuir la capacidad predictiva de un modelo.

Análisis exploratorio de los datos

El tratamiento de valores faltantes es un aspecto fundamental en la preparación de datos. Existen diversas estrategias para abordar los datos faltantes, cada una con sus ventajas y desventajas. A continuación, se presentan algunas de las técnicas más comunes:

- Rellenar con estadísticos descriptivos:
 - Media: consiste en reemplazar los valores faltantes con la media de la variable. Esta técnica es útil cuando los datos siguen una distribución aproximadamente normal y no existe una gran cantidad de valores faltantes.
 - Mediana: utilizar la mediana es una buena opción cuando los datos presentan asimetría o contienen valores atípicos, ya que es menos sensible a estos extremos que la media.
 - Moda: reemplazar con el valor más frecuente es adecuado para variables categóricas.

Análisis exploratorio de los datos

- Rellenar con valores adyacentes: Imputación hacia adelante o hacia atrás: consiste en completar los valores faltantes con el valor de la fila o columna anterior o siguiente. Este método es útil en series temporales, donde los datos suelen estar correlacionados a lo largo del tiempo.
- Rellenar con ceros: Asignación de cero: para valores numéricos, rellenar con cero puede ser una opción simple; sin embargo, generalmente no se recomienda, ya que puede introducir un sesgo significativo y alterar los resultados.
- Eliminar filas: si los datos faltantes están presentes en un número reducido de filas y el conjunto de datos es grande, dichas filas pueden eliminarse. Esta técnica puede ser útil para evitar la imputación, pero debe aplicarse con cuidado para no perder información valiosa.

Análisis exploratorio de los datos

- Imputación con algoritmos de aprendizaje automático:
Modelos predictivos: consiste en utilizar algoritmos para predecir los valores faltantes a partir de otros datos disponibles. Esta técnica puede proporcionar imputaciones más precisas, aunque es más compleja y requiere mayor capacidad computacional.
- Eliminar variables: o Variables con una alta proporción de datos faltantes: en algunos casos, puede ser adecuado eliminar variables que tengan más del 50 % de datos faltantes, especialmente si la variable no es muy relevante para el análisis.

Análisis exploratorio de los datos

Un valor atípico u outlier representa una observación que muestra una desviación significativa respecto al patrón general de comportamiento del resto de los datos. Estas observaciones extremas pueden surgir por diversas razones: desde errores en la medición o en el registro de los datos, hasta fenómenos reales pero extraordinarios que merecen especial atención.

Su importancia dentro del análisis exploratorio es fundamental, ya que pueden ejercer una influencia desproporcionada sobre los estadísticos descriptivos, distorsionar las relaciones entre variables y comprometer la validez de los modelos estadísticos posteriores.

Análisis exploratorio de los datos

Incluir valores atípicos (outliers) en modelos basados en datos puede ser riesgoso. La presencia de un único valor extremo y engañoso tiene el potencial de alterar las conclusiones derivadas del modelo. Por lo tanto, es importante gestionar adecuadamente este tipo de riesgo.


Se muestran los métodos más populares para la detección de valores atípicos:

- Método del rango intercuartílico (IQR).
- Método de la desviación estándar.
- Método de la puntuación Z.
- Método de la puntuación Z modificada.

Análisis exploratorio de los datos


La técnica de Tukey (1977) se utiliza para detectar valores atípicos en datos asimétricos o que no presentan una distribución con forma de campana, ya que no requiere realizar supuestos sobre la distribución de los datos. Sin embargo, el método de Tukey puede no ser adecuado cuando se trabaja con muestras de tamaño reducido.

La regla general establece que cualquier valor que se encuentre fuera del intervalo definido por $(Q_1 - 1.5/IQR)$ y $(Q_3 + 1.5/IQR)$ se considera un valor atípico y puede ser eliminado del conjunto de datos.



Análisis exploratorio de los datos


Método de la desviación estándar. Si sabemos que la distribución de los valores de la muestra es gaussiana, o aproximadamente gaussiana, podemos utilizar la desviación estándar de la muestra como criterio de corte para identificar valores atípicos. La desviación estándar indica qué tan dispersos se encuentran los datos individuales con respecto a la media.



Análisis exploratorio de los datos

Método de la puntuación Z. Al calcular la puntuación Z, se centran y reescalan los datos para identificar aquellas observaciones que se encuentran demasiado alejadas de cero. Esta transformación genera un nuevo conjunto de valores con media igual a 0 y desviación estándar igual a 1.

La puntuación Z describe la posición de un valor original en función de su distancia con respecto a la media, expresada en unidades de desviación estándar.



Puntuación Z modificada. Las puntuaciones Z pueden verse afectadas por la presencia de valores inusualmente grandes o pequeños. Cuando existe un valor extremo, este puede alterar la media y la desviación estándar utilizadas en el cálculo, lo que influye en las puntuaciones Z del conjunto de datos.

Por esta razón, una alternativa más robusta para detectar valores atípicos consiste en utilizar la puntuación Z modificada (Modified Z-score), la cual se basa en la mediana y en la desviación absoluta mediana, medidas menos sensibles a los valores extremos.

Análisis exploratorio de los datos

El enfoque más común para tratar los valores atípicos consiste en reducir su posible influencia sobre los análisis. A continuación, se presentan algunas estrategias que pueden considerarse:

- Métodos estadísticos robustos: existen técnicas estadísticas robustas diseñadas para minimizar el impacto de los valores atípicos en los resultados.
- Eliminación de valores atípicos: eliminar valores atípicos puede ser adecuado en algunos casos, pero debe hacerse con cuidado.
- Sustitución de valores atípicos: consiste, por ejemplo, en reemplazar los valores atípicos por la media o la mediana. Aunque esta práctica puede parecer una solución simple

Análisis exploratorio de los datos

La correlación (r) mide la relación lineal entre dos o más variables, reflejando tanto la fuerza como la dirección de dicha relación. En términos simples, la correlación indica si dos variables cambian conjuntamente y de qué manera lo hacen:

- Correlación positiva: si una variable aumenta y la otra también aumenta, se dice que están correlacionadas positivamente. Un valor de r cercano a 1 indica una relación positiva fuerte.
- Correlación negativa: si una variable aumenta mientras la otra disminuye, se dice que están correlacionadas negativamente. Un valor de r cercano a -1 indica una relación negativa fuerte.
- Sin correlación: un valor de r cercano a 0 sugiere que no existe una relación lineal clara entre las variables.

Análisis exploratorio de los datos

Es importante señalar que la correlación de Pearson, aunque es la más común, no es la única medida de correlación disponible. Existen alternativas como:

- Correlación de Spearman: es más robusta frente a valores atípicos y resulta útil para relaciones monótonas no lineales.
- Correlación de Kendall: es especialmente útil para muestras pequeñas y cuando los datos no siguen una distribución normal.
- Rank-based correlation measures, which can capture non-linear relationships between variables.

Análisis exploratorio de los datos

El análisis de correlación puede ser útil en varios aspectos:

- Identificación de redundancia: puede ayudar a identificar variables redundantes en un conjunto de datos. Si dos variables están altamente correlacionadas, una de ellas podría eliminarse sin perder información significativa.
- Simplicidad en el análisis: en el contexto del análisis exploratorio de datos (EDA), comprender las correlaciones entre variables puede orientar la selección de variables para modelos predictivos.
- Relación con el PCA: el análisis de correlación está relacionado con técnicas como el Análisis de Componentes Principales (PCA). El PCA utiliza la matriz de correlación para transformar las variables originales en un nuevo conjunto de variables, llamadas componentes principales, las cuales capturan la mayor variabilidad presente en los datos.