



Comisión de Acreditación
de la Calidad Académica
UNIVERSIDAD DE ORIENTE - UNIVO
ACREDITADA
2022 - 2027

Clase 07 - Semana 04

Ciencia de datos

Universidad de Oriente
Facultad de Ingeniería y Arquitectura

14 de agosto del 2026





La regresión de Poisson



La regresión de Poisson es una forma especializada de los modelos lineales generalizados, diseñada específicamente para datos de conteo, es decir, para situaciones en las que se intenta predecir el número de veces que ocurre un evento.

A diferencia de la regresión lineal, que supone resultados continuos y distribuciones normales, la regresión de Poisson reconoce que los datos de conteo poseen características particulares: están formados por números enteros no negativos y, con frecuencia, la varianza aumenta a medida que aumenta la media.



La regresión de Poisson



La idea fundamental de la regresión de Poisson es que muchos fenómenos del mundo real siguen una distribución de Poisson, en la que los eventos ocurren de manera independiente y con una tasa promedio constante. Por ello, resulta adecuada para modelar situaciones como el número de quejas de clientes por día, los accidentes de tránsito por mes o las visitas a un sitio web por hora.

El modelo supone que el logaritmo del conteo esperado está relacionado linealmente con las variables predictoras. Esto garantiza que las predicciones permanezcan no negativas y, al mismo tiempo, permite que los predictores tengan efectos multiplicativos sobre el conteo esperado.



La regresión de Poisson



La regresión de Poisson se diferencia de otros modelos de conteo en varios aspectos importantes. Mientras que la regresión logística se centra en resultados binarios, como éxito o fracaso, la regresión de Poisson permite modelar todo el conjunto de números enteros no negativos.

Su principal ventaja es que proporciona un marco natural para comprender cómo las variables predictoras influyen en la tasa con la que ocurren los eventos.

La regresión de Poisson presenta varias ventajas para el análisis de datos de conteo:

- Respeta la naturaleza de los datos de conteo. Proporciona un enfoque fundamentado para modelar variables de conteo, ya que toma en cuenta que los datos son discretos y no negativos.
- Garantiza predicciones positivas. A diferencia de la regresión lineal, que puede producir predicciones negativas sin sentido en problemas de conteo, la regresión de Poisson garantiza que todos los valores predichos sean positivos. Esto hace que los resultados sean interpretables y realistas.
- Facilita la comunicación de los resultados. La interpretación mediante razones de tasas permite explicar con facilidad los resultados a personas sin formación estadística y comprender el efecto práctico de los diferentes factores.
- Es computacionalmente eficiente. La regresión de Poisson puede estimarse de manera rápida, incluso cuando se trabaja con conjuntos de datos relativamente grandes.

A pesar de sus ventajas, la regresión de Poisson presenta varias limitaciones que deben considerarse:

- Supone equidispersión. La limitación más importante es que el modelo asume que la varianza es igual a la media. Sin embargo, en la práctica, los datos de conteo suelen presentar sobredispersión, es decir, una varianza mayor que la media.
- Puede subestimar los errores estándar. Cuando existe sobredispersión y se utiliza un modelo de Poisson convencional, los errores estándar pueden quedar subestimados y los valores (p) pueden resultar excesivamente pequeños. Esto puede producir falsos hallazgos y conclusiones incorrectas sobre la significancia de las variables predictoras.
- Supone independencia entre los eventos. El modelo considera que los eventos ocurren de manera independiente, pero esta condición puede no cumplirse en muchas situaciones reales.



El fundamento de la regresión de Poisson se encuentra en la distribución de Poisson, la cual describe la probabilidad de observar exactamente k eventos cuando estos ocurren de manera independiente y con una tasa promedio constante λ .

La función de masa de probabilidad de la distribución de Poisson, que constituye la base de la regresión de Poisson, está dada por:

$$P(Y = k) = \frac{e^{-\lambda} \lambda^k}{k!}, \quad k = 0, 1, 2, 3, \dots$$

En el contexto de la regresión de Poisson, λ no es un valor fijo, sino que se modela como una función de las variables predictoras. Esto permite comprender cómo diferentes factores influyen en el número esperado de eventos.



En la regresión de Poisson, el objetivo es modelar la relación entre un conjunto de variables predictoras y la tasa esperada con la que ocurren los eventos, representada por el parámetro λ . Este parámetro corresponde al número promedio de ocurrencias para un conjunto determinado de valores de las variables predictoras.

Como λ debe ser positiva, ya que una tasa de ocurrencia no puede ser negativa, se utiliza una función de enlace logarítmica para relacionar la combinación lineal de las variables predictoras con λ . Esta función se conoce como función de enlace logarítmica y constituye una característica fundamental de la regresión de Poisson. El modelo se formula como



$$\log(\lambda_i) = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip}.$$

Donde se tiene:

- λ_i es el conteo esperado o parámetro de tasa para la observación i , donde $\lambda_i > 0$. Representa la media de la distribución de Poisson correspondiente a la observación i .
- β_0 es el intercepto. Representa el logaritmo del conteo esperado cuando todas las variables predictoras son iguales a cero.
- $\beta_1, \dots, \beta_p$ son los coeficientes asociados con cada variable predictora. Cada coeficiente representa el cambio en el logaritmo del conteo esperado producido por un incremento de una unidad en la variable predictora correspondiente, manteniendo constantes las demás variables.
- $x_{i1}, \dots, x_{ip}$ son los valores de las variables predictoras para la observación i ; es decir, los valores de las características correspondientes a la i -ésima observación.

En las siguientes visualizaciones, el modelo captura la tendencia exponencial general presente en los datos: a medida que aumenta la variable predictora, el conteo esperado crece rápidamente, de manera coherente con la función de enlace logarítmica que se muestra en el tercer gráfico.

La mayoría de los puntos observados se agrupan alrededor de la curva ajustada, lo que indica que el modelo describe adecuadamente el patrón principal de los datos.



Scikit-learn proporciona una implementación sencilla de la regresión de Poisson mediante la clase `PoissonRegressor`, la cual resulta adecuada para tareas de modelado predictivo. A continuación, se presentan los principales parámetros que controlan el funcionamiento y el rendimiento de `PoissonRegressor`.

- `alpha`: intensidad de la regularización (valor predeterminado: 1.0).
- `max_iter`: número máximo de iteraciones del proceso de optimización (valor predeterminado: 100).

Puede aumentarse a 1000 o más cuando aparecen advertencias de convergencia, especialmente con conjuntos de datos grandes o muchas variables predictoras.

- `tol`: tolerancia de convergencia (valor predeterminado: $1e-4$).

Los valores más pequeños requieren una convergencia más precisa, pero aumentan el tiempo de cálculo.



Los siguientes métodos se utilizan habitualmente para trabajar con modelos de regresión de Poisson.

- `fit(X, y)`: entrena el modelo utilizando la matriz de características X y la variable objetivo de conteo y .
- `predict(X)`: devuelve los conteos esperados predichos para las características de entrada X .
- `score(X, y)`: devuelve el negativo de la desviación media de Poisson para los datos proporcionados.