

Universidad de Oriente	
Ciencia de datos	Clase 08 - Ejemplo 1 - Regresión de Poisson

```
In [87]: import numpy as np
from sklearn.linear_model import PoissonRegressor
import matplotlib.pyplot as plt
import pandas as pd
```

Se dispone de un conjunto de datos que contiene información diaria relacionada con el alquiler de bicicletas, incluyendo variables meteorológicas, temporales y características del día. Entre las variables disponibles se encuentran la temperatura, temperatura aparente, humedad, velocidad del viento, estación del año, mes, presencia de días festivos, día de la semana, condición laboral del día, situación meteorológica y el número total de bicicletas alquiladas. El conjunto de datos contiene 731 observaciones.

A partir de los datos proporcionados, realice lo siguiente:

- Explore el conjunto de datos e identifique el comportamiento de las principales variables cuantitativas mediante representaciones gráficas.
- Construya un modelo de regresión de Poisson simple utilizando la temperatura aparente (atemp) como variable independiente y el número total de alquileres (cnt) como variable dependiente. Interprete el coeficiente obtenido y evalúe el ajuste del modelo mediante el valor de (D^2).
- Analice la significancia estadística de la variable atemp mediante un modelo lineal generalizado con distribución de Poisson.
- Construya un modelo de regresión de Poisson múltiple utilizando las variables meteorológicas, temporales y relacionadas con las características del día incluidas en el ejemplo.
- Interprete los coeficientes obtenidos en el modelo múltiple y determine cuáles variables presentan una asociación positiva o negativa con el número esperado de alquileres.
- Evalúe el desempeño del modelo múltiple mediante el valor de (D^2), analice los residuos y compare gráficamente los valores reales con los valores predichos.

```
In [89]: datos_poisson = pd.read_csv("day.csv")
```

```
In [91]: datos_poisson
```

Out[91]:

	instant	dteday	season	yr	mnth	holiday	weekday	workingday	weathersit	
0	1	2011-01-01	1	0	1	0	6	0	2	0.0
1	2	2011-01-02	1	0	1	0	0	0	2	0.0
2	3	2011-01-03	1	0	1	0	1	1	1	0.0
3	4	2011-01-04	1	0	1	0	2	1	1	0.0
4	5	2011-01-05	1	0	1	0	3	1	1	0.0
...	...	...	...	...	...	...	...	...	...	...
726	727	2012-12-27	1	1	12	0	4	1	2	0.0
727	728	2012-12-28	1	1	12	0	5	1	2	0.0
728	729	2012-12-29	1	1	12	0	6	0	2	0.0
729	730	2012-12-30	1	1	12	0	0	0	1	0.0
730	731	2012-12-31	1	1	12	0	1	1	2	0.0

731 rows × 16 columns



```
In [93]: datos_poisson.info()
```

```

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 731 entries, 0 to 730
Data columns (total 16 columns):
#   Column      Non-Null Count  Dtype
---  -
0   instant     731 non-null    int64
1   dteday      731 non-null    object
2   season      731 non-null    int64
3   yr          731 non-null    int64
4   mnth        731 non-null    int64
5   holiday     731 non-null    int64
6   weekday     731 non-null    int64
7   workingday  731 non-null    int64
8   weathersit   731 non-null    int64
9   temp        731 non-null    float64
10  atemp       731 non-null    float64
11  hum         731 non-null    float64
12  windspeed   731 non-null    float64
13  casual      731 non-null    int64
14  registered  731 non-null    int64
15  cnt         731 non-null    int64
dtypes: float64(4), int64(11), object(1)
memory usage: 91.5+ KB

```


In [167... `datos_poisson.describe()`

Out[167...

	instant	season	yr	mnth	holiday	weekday	working
count	731.000000	731.000000	731.000000	731.000000	731.000000	731.000000	731.000000
mean	366.000000	2.496580	0.500684	6.519836	0.028728	2.997264	0.683198
std	211.165812	1.110807	0.500342	3.451913	0.167155	2.004787	0.465049
min	1.000000	1.000000	0.000000	1.000000	0.000000	0.000000	0.000000
25%	183.500000	2.000000	0.000000	4.000000	0.000000	1.000000	0.000000
50%	366.000000	3.000000	1.000000	7.000000	0.000000	3.000000	1.000000
75%	548.500000	3.000000	1.000000	10.000000	0.000000	5.000000	1.000000
max	731.000000	4.000000	1.000000	12.000000	1.000000	6.000000	1.000000

In [95]: `plt.figure()`
`datos_poisson[["temp", "atemp", "hum", "windspeed", "casual", "registered", "cnt"]]`
`plt.show()`


<Figure size 640x480 with 0 Axes>



El análisis exploratorio muestra diferencias importantes en la distribución de las variables. temp y atemp presentan comportamientos similares, mientras que casual muestra una distribución claramente asimétrica hacia la derecha. La variable cnt, que representa el número total de alquileres de bicicletas, presenta una amplia variabilidad, con registros que van desde valores muy bajos hasta superiores a 8000 alquileres diarios.

```
In [96]: X_independiente = datos_poisson["atemp"]
         respuesta = datos_poisson["cnt"]
```

```
In [97]: plt.figure()
         plt.scatter(X_independiente, respuesta)
         plt.xlabel("Temperatura")
         plt.ylabel("Conteos")
         plt.show()
```



La gráfica de dispersión también evidencia una tendencia general creciente entre ambas variables, aunque existe una considerable variabilidad alrededor de la curva ajustada.

```
In [98]: #Crear el modelo de regresión
poisson_reg = PoissonRegressor()
poisson_reg.fit(X_independiente.values.reshape(-1,1), respuesta)
```

```
Out[98]: PoissonRegressor
```

```
PoissonRegressor()
```

```
In [99]: #Mostrar el coeficiente
print("El coeficiente que se obtiene es %s" %poisson_reg.coef_)
```

El coeficiente que se obtiene es [1.7021979]

```
In [101]: #Mostrar el intercepto
print("El intercepto que se obtiene es %s" %poisson_reg.intercept_)
```

El intercepto que se obtiene es 7.567628812263883

El modelo simple obtiene un coeficiente para atemp de aproximadamente 1.7022 y un intercepto de 7.5676. El coeficiente positivo indica que, a medida que aumenta la temperatura aparente, también aumenta el número esperado de alquileres de bicicletas.


```
In [104]: #Mostrar el valor del D^2
print("El valor del D^2 obtenido es %s" %poisson_reg.score(X_independiente.value
```

El valor del D^2 obtenido es 0.3688260279754014

El modelo simple obtiene un valor de $D^2 = 0.3688$ lo que indica que la temperatura aparente explica aproximadamente un 36.9 % de la desviación respecto a un modelo que únicamente utiliza el intercepto. Por tanto, atemp posee capacidad explicativa, pero por sí sola no logra representar una parte importante de la variabilidad del número de alquileres

```
In [108... X_independiente_ord = datos_poisson["atemp"].sort_values().copy()
y_pred = poisson_reg.predict(X_independiente_ord.values.reshape(-1,1))

plt.figure()
plt.scatter(datos_poisson["atemp"], respuesta, color="orange")
plt.plot(X_independiente_ord, y_pred)
plt.xlabel("Temperatura")
plt.ylabel("Conteos")
plt.show()
```



```
In [110... import statsmodels.api as sm
X2 = sm.add_constant(X_independiente)
modelo_poisson_a = sm.GLM(respuesta, X2, family=sm.families.Poisson())
resultados = modelo_poisson_a.fit()
```

```
In [111... print(resultados.summary())
```

Generalized Linear Model Regression Results

=====						
Dep. Variable:	cnt	No. Observations:	731			
Model:	GLM	Df Residuals:	729			
Model Family:	Poisson	Df Model:	1			
Link Function:	Log	Scale:	1.0000			
Method:	IRLS	Log-Likelihood:	-2.1475e+05			
Date:	Sat, 15 Aug 2026	Deviance:	4.2211e+05			
Time:	09:44:30	Pearson chi2:	4.05e+05			
No. Iterations:	5	Pseudo R-squ. (CS):	1.000			
Covariance Type:	nonrobust					
=====						
	coef	std err	z	P> z	[0.025	0.975]

const	7.5597	0.002	3973.173	0.000	7.556	7.563
atemp	1.7175	0.004	489.029	0.000	1.711	1.724
=====						

En el modelo ajustado con statsmodels, el coeficiente de atemp es aproximadamente 1.7175, con un valor $p < 0.001$. Esto proporciona evidencia estadística de que la temperatura aparente está asociada significativamente con el número esperado de alquileres

```
In [138... #Regresión múltiple
predictoras = datos_poisson[["temp", "atemp", "hum", "windspeed", "season", "yr", "mn",
                             "workingday", "weathersit"]]
```

```
In [140... #Particionar los datos en entrenamiento y validación
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(predictoras, respuesta, test_si
```

```
In [146... #Crear el modelo de regresión
poisson_reg_b = PoissonRegressor(max_iter=300)
poisson_reg_b.fit(X_train, y_train)
```

```
Out[146... PoissonRegressor
PoissonRegressor(max_iter=300)
```

```
In [148... #Mostrar coeficientes
coefs = poisson_reg_b.coef_
pd.DataFrame({"Variables": predictoras.columns, "Coeficientes": coefs})
```

Out[148...

	Variables	Coeficientes
0	temp	0.364693
1	atemp	0.894506
2	hum	-0.138347
3	windspeed	-0.511343
4	season	0.141197
5	yr	0.463016
6	mnth	-0.009192
7	holiday	-0.106124
8	weekday	0.017857
9	workingday	0.021191
10	weathersit	-0.175503

In [150...

```
#Mostrar el intercepto
print("El intercepto de la regresión de Poisson es %s" %poisson_reg_b.intercept_
```

El intercepto de la regresión de Poisson es 7.564140801622013

En el modelo múltiple se incluyen temp, atemp, hum, windspeed, season, yr, mnth, holiday, weekday, workingday y weathersit. Los coeficientes muestran que algunas variables presentan asociaciones positivas con el número esperado de alquileres, mientras que otras presentan asociaciones negativas.

In [152...

```
#Valor del D^2
print("El valor del D^2 es %s" %poisson_reg_b.score(X_train,y_train))
```

El valor del D^2 es 0.7746019853960119

In [154...

```
import statsmodels.api as sm
X2 = sm.add_constant(X_train)
modelo_poisson_b = sm.GLM(y_train, X2, family=sm.families.Poisson())
resultados_b = modelo_poisson_b.fit()
```

In [156...

```
print(resultados_b.summary())
```


Generalized Linear Model Regression Results

=====						
Dep. Variable:		cnt	No. Observations:		548	
Model:		GLM	Df Residuals:		536	
Model Family:		Poisson	Df Model:		11	
Link Function:		Log	Scale:		1.0000	
Method:		IRLS	Log-Likelihood:		-59009.	
Date:	Sat, 15 Aug 2026	Deviance:		1.1247e+05		
Time:	09:46:17	Pearson chi2:		1.05e+05		
No. Iterations:	5	Pseudo R-squ. (CS):		1.000		
Covariance Type:		nonrobust				
=====						
	coef	std err	z	P> z	[0.025	0.975]

const	7.5599	0.005	1456.641	0.000	7.550	7.570
temp	0.1703	0.024	7.004	0.000	0.123	0.218
atemp	1.1220	0.028	40.417	0.000	1.068	1.176
hum	-0.1487	0.006	-23.576	0.000	-0.161	-0.136
windspeed	-0.5254	0.009	-55.690	0.000	-0.544	-0.507
season	0.1403	0.001	110.497	0.000	0.138	0.143
yr	0.4631	0.001	344.866	0.000	0.461	0.466
mnth	-0.0091	0.000	-22.190	0.000	-0.010	-0.008
holiday	-0.1057	0.005	-22.525	0.000	-0.115	-0.097
weekday	0.0180	0.000	55.421	0.000	0.017	0.019
workingday	0.0212	0.001	14.959	0.000	0.018	0.024
weathersit	-0.1737	0.002	-107.506	0.000	-0.177	-0.171
=====						

El modelo GLM muestra que todas las variables incluidas presentan valores $p < 0.001$, por lo que, dentro de este ajuste, existe evidencia estadística de asociación entre cada predictor y el número esperado de alquileres.

In [160...


```

y_pred = poisson_reg_b.predict(X_test)

residuos = y_test - y_pred

#Graficar los residuos
plt.figure()
plt.scatter(residuos.index, residuos)
plt.plot([0, np.max(residuos.index)], [0, 0], color="red", linewidth=2)
plt.title("Residuos")
plt.show()


```



In [162...

```
indices_test = X_test.index
fechas_test = datos_poisson["dteday"][indices_test]

plt.figure()
plt.plot(fechas_test, y_test, 'go-', label='Valores reales')
plt.xticks([], [])
plt.plot(fechas_test, y_pred, 'ro-', label='Valores predichos')
plt.legend()
plt.show()
```



La gráfica de residuos muestra observaciones tanto por encima como por debajo de cero, aunque existen errores de magnitud considerable en ciertos registros. Asimismo, la comparación entre valores reales y predichos muestra que el modelo reproduce en términos generales el comportamiento de los conteos, pero todavía presenta diferencias importantes para determinadas observaciones.

In []:

In []: